한국문화 멀티모달 질의응답을 위한 멀티모달 검색 증강 생성

김준형[†,*], 곽혜진[†,°], 이신영[†], 이정빈[†]
홍익대학교, 숙명여자대학교, 고려대학교, 성균관대학교
kimjunhyung0902@naver.com; hyejinkwak701@gmail.com;
uriyoung11@korea.ac.kr; jeongbin511@gmail.com
[†]공동 제1저자, [*]교신저자, [°]발표자

Multimodal Retrieval-Augmented Generation for Korean Culture Multimodal Question Answering

Junhyung Kim[†,*], Hyejin Kwak[†,°], Shinyoung Lee[†], Jeongbin Lee[†]
Hongik University, Sookmyung Women's University, Korea University, Sungkyunkwan University

요 약

최근 멀티모달 대규모 언어 모델(Multimodal Large Language Model, MLLM)의 발전으로 이미지 기반 질의응답 성능이 크게 향상되었지만, 한국문화 멀티모달 질의응답은 이미지 이해와 더불어 문화재, 유물, 전통문화 등에 관한 세부 배경지식을 요구한다. 대규모 MLLM은 이러한 지식을 사전학습으로 습득할 수 있으나 모델 규모와 학습 데이터에 크게 의존한다. 본 연구는 상대적으로 작은 MLLM의 내부 지식 한계를 외부 지식 검색으로 보완할 수 있는지 분석하기 위해 한국문화 외부 지식을 활용하는 멀티모달 검색 증강 생성 프레임워크를 제안한다. 질문, 선택지 및 이미지 내 문자 정보를 활용하는 텍스트 검색과 입력 이미지의 시각 특징을 활용하는 이미지 검색을 결합하고, 검색된 문서를 Kanana-1.5-V-3B-Instruct의 답변 생성에 활용한다. 실험 결과, 멀티모달 RAG를 적용한 Kanana는 종합 점수 47.07을 기록하여 RAG를 적용하지 않은 Kanana보다 3.93점, 텍스트 RAG보다 1.96점 향상되었으며, 33B 규모 EXAONE의 46.99에 필적하는 성능을 보였다. 또한 500개의 학습 데이터를 추가한 설정에서는 종합 점수가 47.40으로 향상되었다.

주제어: 멀티모달 대규모 언어 모델, 검색 증강 생성, 멀티모달 질의응답, 한국문화, 지식 기반 시각 질의응답

1. 서론

최근 MLLM의 발전으로 이미지 기반 질의응답 성능이 크게 향상되었다. 그러나 한국문화 멀티모달 시각 질의응답(Visual Question Answering, VQA)은 이미지 이해뿐 아니라 문화재, 유물, 전통문화 등에 관한 세부적인 배경지식을 요구한다. 이러한 지식은 일반적인 소형 MLLM의 내부 지식만으로 충분히 다루기 어렵다.

이 문제를 분석하기 위해 한국어 MLLM인 EXAONE-4.5-33B [1]와 Kanana-1.5-V-3B-Instruct [2]를 비교한다. EXAONE은 대규모 모델일 뿐 아니라 한국문화 관련 멀티모달 데이터를 사전학습에 포함하여 한국문화 지식 측면에서도 유리한 반면, Kanana는 3B 규모의 상대적으로 경량인 모델로 학습 및 추론 효율성이 높다. 이에 본 연구는 소형 Kanana에 외부 한국문화 지식을 결합하여 EXAONE과 경쟁 가능한 성능을 달성할 수 있는가를 주요 연구 질문으로 설정한다.

이를 위해 질문, 선택지 및 이미지 내 문자 정보를 활용하는 Text Retrieval과 입력 이미지의 시각적 특징을 활용하는 Image Retrieval을 결합한 멀티모달 검색 증강 생성(Multimodal Retrieval-Augmented Generation, Multimodal RAG) 프레임워크를 제안한다. 본 연구의 기여는 다음과 같다. 첫째, EXAONE 33B와 Kanana 3B를 비교하여 한국문화 VQA에서 모델 규모와 사전지식에 따른 성능 차이를 분석한다. 둘째, 한국문화 외부 지식을 활용하는 텍스트/이미지 멀티모달 RAG 구조를 제안한다. 셋째, 소형 3B MLLM과 외부 지식 검색의 결합이 한국문화 지식을 강하게 사전학습한 33B MLLM과 경쟁 가능한 성능을 달성할 수 있는지 검증한다.

2. 관련 연구

2.1 멀티모달 대규모 언어 모델

텍스트만을 처리하던 대규모 언어모델(LLM)은 대규모 이미지-텍스트 사전학습과 시각 인코더의 결합을 통해 시각·언어 정보를 통합적으로 처리하는 MLLM으로 발전하였다.

대표적인 범용 MLLM으로는 Qwen 계열을 들 수 있다. Qwen2.5-VL은 향상된 시각 인식, 세밀한 객체 위치 파악, 문서 이해 및 장시간 비디오 이해 능력을 제공하며 [3], 후속 모델 Qwen3-VL은 텍스트, 이미지 및 비디오를 아우르는 최대 256K 토큰 컨텍스트와 다양한 크기의 dense 및 MoE 모델을 제공한다 [4].

국내에서도 한국어에 특화된 MLLM 개발이 이루어지고 있다. Kanana는 한국어와 영어를 지원하는 모델 계열로 한국어 환경의 언어 이해 및 생성 능력을 강화하였으며, 검색 증강 생



그림 1. 제안하는 한국문화 멀티모달 RAG 프레임워크의 전체 구조.

성과 같은 외부 지식 활용을 위한 적응 방법도 함께 제시하였다 [5]. EXAONE 4.5는 LG AI Research의 비전-언어 모델로, EXAONE 4.0 기반 언어 모델에 시각 인코더를 통합하여 텍스트-이미지 네이티브 멀티모달 사전학습을 수행한다. 특히 한국의 문화적, 언어적 맥락을 학습하기 위해 한국관광공사의 이미지와 설명을 포함한 한국어 특화 멀티모달 말뭉치를 사전학습에 활용하였다 [1].

MLLM의 시각 및 언어 이해 능력이 향상되었음에도 세부 개체에 관한 전문적인 외부 지식을 요구하는 KB-VQA에는 여전히 한계가 존재한다. Encyclopedic-VQA는 이미지 속 개체의 세부 백과사전 지식을 요구하는 벤치마크를 통해, 기존 시각-언어 모델이 이미지를 이해하더라도 개체의 세부 지식 질문에는 취약할 수 있음을 보였다 [6]. 이는 문화재나 역사적 유물처럼 세부 외부 지식을 요구하는 과제에서 MLLM 자체의 지식과 함께 외부 지식베이스를 활용할 필요가 있음을 시사한다.

2.2 텍스트 검색 증강 생성

대규모 사전학습 언어 모델은 파라미터 내부에 방대한 지식을 저장하지만 학습 이후 등장한 지식을 반영하기 어렵다. RAG(Retrieval-Augmented Generation)는 언어 모델의 매개변수적 메모리와 검색된 외부 문서의 비매개변수적 메모리를 결합하여 답변을 생성한다 [7]. 검색 단계에서는 질의와 문서를 동일한 벡터 공간에 표현하는 Dense Passage Retrieval이 대표적으로 활용되었다 [8]. 이후 Self-RAG는 모델이 검색 필요성과 검색 정보 및 생성 결과를 평가하는 reflection mechanism을 도입하였고 [9], Corrective RAG는 검색 품질이 낮을 때 추가 검색과 정보 정제를 수행한다 [10].

그러나 텍스트 기반 RAG를 멀티모달 질의응답에 그대로 적용하면 이미지에만 존재하는 시각 정보를 검색 과정에 직접 활용하기 어렵다. 특히 질문이나 이미지 내 문자 정보에 대상의 명칭이 명시되지 않은 경우, 텍스트만으로 검색 대상을 특정하기 어렵다.

2.3 멀티모달 검색 증강 생성

이러한 텍스트 RAG의 한계를 해결하기 위해 최근에는 이미지와 텍스트를 검색 과정에 함께 활용하는 멀티모달 RAG가 연구되고 있다. MuRAG는 텍스트와 이미지로 구성된 멀티모달 메모리에서 두 모달리티의 정보를 함께 검색하여 생성 모델에 제공하였다 [11]. Wiki-LLaVA는 외부 위키피디아 지식베이스에 계층적 검색을 적용하여 검색된 지식을 MLLM의 추가 컨텍스트로 주입한다 [12].

2.4 파라미터 효율적 미세조정

LoRA(Low-Rank Adaptation)는 대표적인 Parameter-Efficient Fine-Tuning(PEFT) 방법으로, 사전학습된 가중치를 고정하고 Transformer의 가중치 변화량을 저랭크 행렬의 곱으로 표현하여 소수의 파라미터만 학습한다 [13]. 본 연구에서는 Kanana의 attention projection layer에 LoRA를 적용하여 한국문화 질의응답 및 외부 지식 활용 능력을 학습한다.

또한 Adapter 기반 방법은 사전학습 모델의 대부분을 공유하고 과제별 소규모 파라미터를 독립적으로 학습할 수 있음을 보여주었으며, 이러한 개념은 하나의 공유된 표현 능력을 먼저 학습한 후 과제별 특성에 맞게 추가적으로 적응시키는 본 연구의 학습 구조와 관련된다.

3. 방법론

3.1 전체 구조

본 연구는 한국문화 외부 지식을 활용하여 멀티모달 질의응답 성능을 높이는 프레임워크를 제안한다. 전체 구조는 그림 1과 같다. 입력 이미지와 질문을 바탕으로 텍스트와 이미지의 두 관점에서 관련 지식을 검색한다. Text Retrieval은 입력 이미지와 질문에서 얻은 언어적 단서를 사용하고, Image Retrieval은

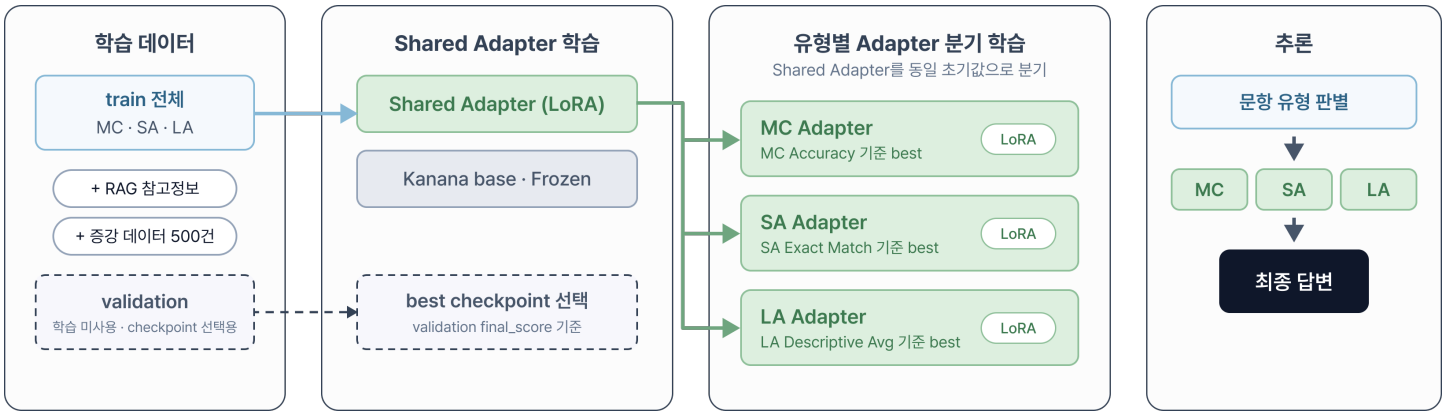


그림 2. Shared Adapter 학습과 문항 유형별 Adapter 분기 학습.

입력 이미지와 데이터베이스 이미지 사이의 시각적 유사도를 사용한다. 두 검색 결과를 통합하여 관련성이 높은 문서를 선택한 뒤, 문서의 설명을 RAG 참고정보로 구성하여 답변 생성 모델에 제공한다.

3.2 한국문화 외부 지식 데이터베이스 구축

한국문화 질의응답에 필요한 외부 지식을 확보하기 위해 한국민족문화대백과사전, 한국민속대백과사전, 국립중앙박물관 e뮤지엄, 국가유산포털 및 법제처의 총 5개 공공 데이터 소스에서 한국문화 관련 데이터를 수집하였다. 서로 다른 필드 구조를 공통 스키마로 정규화하여 한국문화 지식 데이터베이스를 구축하였다.

각 문화 대상 또는 지식 항목을 하나의 문서로 구성하고, 문서 식별자(`doc_id`), 출처(`source`), 제목(`title`), 검색어(`search_terms`), 설명(`description`) 및 관련 이미지(`image`)를 저장하였다. 검색어에는 문서의 주요 명칭과 관련 표현을, 설명에는 검색 후 Kanana에 제공할 외부 지식을 저장하였다. 관련 이미지를 함께 저장하여 텍스트 및 이미지 검색에 모두 활용하였다.

정규화된 문서는 Qdrant 기반 벡터 데이터베이스에 저장하였다. 텍스트 검색을 위해 검색어를 한국어 임베딩 모델 KURE-v1 [14]으로 벡터화하고, 이미지는 CLIP ViT-B/32 [15]로 시각 특징 벡터를 생성하였다. 텍스트와 이미지 벡터는 코사인 유사도로 검색한다.

3.3 Text 기반 지식 검색

입력 이미지와 질문을 Base Kanana에 제공하여 외부 지식 검색에 적합한 핵심 질의어를 생성한다. 질의어는 특정 문화 대상을 식별하는 데 유용한 명사구를 중심으로 최대 5개까지 생성한다. 각 질의어가 문서 제목과 정확히 일치하면 해당 문서를 직접 포함한다. 그렇지 않으면 질의어를 KURE-v1으로 임베딩하여 문서 검색어 벡터와 코사인 유사도를 계산한다. m개의 질의어 집합을 $Q = \{q_1, \ldots, q_m\}$라 할 때 문서 d_i의 텍스트 검색 점수는

$$s_{\text{text}}(d_i) = \max_{q_j \in Q} s_{\text{text}}(d_i, q_j) \tag{1}$$

로 정의하며, $s_{\text{text}}(d_i) \geq 0.9$인 문서만 후보로 사용한다.

3.4 Image 기반 지식 검색

입력 이미지를 검색 질의로 사용하여 텍스트 검색과 독립적으로 관련 한국문화 지식을 탐색한다. 입력 이미지를 I, 문서 d_i의 n개 이미지 집합을 $\mathcal{I}_i = \{I_{i,1}, \ldots, I_{i,n}\}$라 할 때, 문서 d_i의 이미지 검색 점수는

$$s_{\text{image}}(d_i) = \max_{I_{i,j} \in \mathcal{I}_i} \text{sim}(f_{\text{CLIP}}(I), f_{\text{CLIP}}(I_{i,j})) \tag{2}$$

로 정의하며, $s_{\text{image}}(d_i) \geq 0.9$인 문서만 후보로 사용한다.

3.5 Text/Image 검색 결과 결합

두 검색 경로의 후보 문서를 문서 식별자로 통합한다. 같은 문서가 두 경로에서 모두 검색되면 텍스트 및 이미지 검색 점수를 함께 반영한다. 문서 d_i의 최종 검색 점수는

$$s_{\text{final}}(d_i) = s_{\text{text}}(d_i) + s_{\text{image}}(d_i) \tag{3}$$

로 정의한다. 통합 후보를 식 (3)에 따라 정렬하여 최대 3개의 문서를 선택하고, 선택된 문서의 설명을 RAG 참고정보로 구성한다. 후보 문서가 없으면 RAG 참고정보를 제공하지 않는다. 검색 문서의 설명은 정답이 아닌 참고정보로 제공하며, 입력 이미지 및 질문과 관련 없는 정보는 무시하도록 프롬프트를 구성한다.

3.6 단계적 Adapter 학습 및 답변 생성

검색된 외부 지식을 효과적으로 활용하도록 Kanana에 LoRA 기반 미세조정을 수행한다. 그림 2와 같이 MC, SA 및 LA 전체 train 데이터로 Shared Adapter를 먼저 학습하여 문제 유형에 공통적으로 필요한 한국문화 지식 활용 능력과 질의응답 표현을 학습한다. 이후 Shared Adapter를 동일한 초기값으로 사용하여 MC, SA 및 LA 유형별 Adapter를 독립적으로

표 1. Kanana와 EXAONE의 한국문화 멀티모달 질의응답 성능 비교.

모델	종합 점수	MC Acc	SA EM	LA Desc Avg
Kanana	43.14	72.77	27.67	28.99
EXAONE	46.99	75.90	31.55	33.52

표 2. 검색 방식에 따른 Kanana의 성능 비교.

모델	종합 점수	MC Acc	SA EM	LA Desc Avg
Kanana	43.14	72.77	27.67	28.99
Kanana + Text RAG	45.11	72.29	28.64	34.39
Kanana + Multimodal RAG	47.07	72.29	32.52	36.39

추가 학습한다. 이는 공통 능력을 공유하면서도 각 문제 유형에 특화된 응답 능력을 확보하기 위함이다. 추론 시에는 문항 유형에 대응하는 Adapter를 선택하여 최종 답변을 생성한다.

4. 실험

4.1 실험 환경

본 연구는 국립국어원 AI말평 한국문화 멀티모달 질의응답 데이터셋 [16]을 사용하였다. 데이터셋은 train 1,000문항, validation 200문항, test 800문항으로 구성되며, 문항 유형별로 MC는 Accuracy, SA는 Exact Match, LA는 ROUGE-1 F1과 BLEU-1의 평균으로 평가한다. 종합 점수는 세 지표의 산술평균이며, 이후 보고하는 모든 성능은 AI말평 공식 평가 시스템에서 test 800문항에 대해 측정한 결과이다.

기본 MLLM으로 Kanana-1.5-V-3B-Instruct를 사용하였다. 전체 파라미터를 미세조정하는 대신 Language Model의 self-attention에 포함된 `q_proj`, `k_proj`, `v_proj` 및 `o_proj`에 LoRA를 적용하고 Vision Encoder와 Abstractor는 고정하였다. LoRA rank는 16, alpha는 32로 설정하였다.

Shared Adapter의 learning rate는 2×10^{-5}, 유형별 Adapter의 learning rate는 1×10^{-5}로 설정하였다. Shared Adapter는 최대 5 epoch, 유형별 Adapter는 최대 10 epoch 학습하였다. Shared Adapter는 validation 종합 점수, 유형별 Adapter는 각각 MC Accuracy, SA Exact Match 및 LA Descriptive Avg를 기준으로 최적 checkpoint를 선택하였다. 검증 성능이 연속 2 epoch 동안 향상되지 않으면 조기 종료하였다.

4.2 MLLM 모델 비교

한국문화 멀티모달 질의응답의 기본 모델을 선정하기 위해 Kanana-1.5-V-3B-Instruct와 EXAONE-4.5-33B를 동일한 학습 데이터와 LoRA 기반 미세조정 조건에서 비교하였다. 표 1에서 EXAONE은 종합 점수 46.99로 Kanana의 43.14보다 3.85점 높았다. EXAONE의 MC Accuracy와 SA Exact Match는 각각 75.90%와 31.55%로 Kanana보다 3.13%p와 3.88%p 높았다. LA Descriptive Avg에서도 EXAONE은 33.52로 Kanana의 28.99보다 4.53점 높았다.

본 연구는 대규모 모델의 내부 지식을 소규모 모델이 외부 검색으로 보완할 수 있는지에 주목한다. 따라서 3B 규모 Kanana를 기본 모델로 선정하고 한국문화 외부 지식을 활용한 Multimodal RAG로 대규모 모델과의 성능 격차를 완화할 수 있는지 검증한다.

표 3. 500개 학습 데이터 추가 전후 성능 비교.

모델	종합 점수	MC Acc	SA EM	LA Desc Avg
Kanana + Multimodal RAG	47.07	72.29	32.52	36.39
Kanana + Multimodal RAG + Data Aug	47.40	73.25	31.07	37.88

4.3 검색 증강 생성 성능 비교

외부 지식 검색의 영향을 분석하기 위해 외부 지식을 사용하지 않는 Kanana, 텍스트 검색만 사용하는 Kanana + Text RAG, 텍스트와 이미지 검색을 함께 사용하는 Kanana + Multimodal RAG를 비교하였다. 표 2에서 Text RAG의 종합 점수는 43.14에서 45.11로 1.97점 향상되었다. Multimodal RAG는 47.07을 기록하여 Text RAG보다 1.96점, RAG를 적용하지 않은 Kanana보다 3.93점 높았다. MC Accuracy는 72.77%에서 72.29%로 0.48%p 감소했지만 SA Exact Match는 27.67%에서 32.52%로 4.85%p, LA Descriptive Avg는 28.99에서 36.39로 7.40점 증가하였다.

Kanana + Multimodal RAG의 종합 점수 47.07은 앞선 모델 비교에서 33B 규모 EXAONE이 기록한 46.99를 수치상 소폭 상회하였다. 이 결과는 소규모 MLLM도 도메인 특화 외부 지식을 적절히 검색하여 제공하면 제한된 내부 지식을 보완할 수 있음을 보여준다.

4.4 데이터 증강에 따른 추가 분석

증강 문항 500개는 5개 공공 데이터 소스에서 수집한 한국문화 지식 데이터베이스에서 Gemini 2.5 Flash로 생성하였다. 원본 데이터의 실제 유형 비율(MC 51.8%/SA 25.3%/LA 22.9%)을 유지하도록 구성하였다.

증강 데이터의 효과를 확인하기 위해 기존 train 데이터에 추가하고 같은 설정에서 학습하였다. 표 3에서 종합 점수는 47.07



그림 3. Text Retrieval의 정성적 사례: (가) 질문에 문화 대상의 명칭이 제시된 경우, (나) 이미지 내 문자 정보가 검색 단서인 경우.



그림 4. Image Retrieval의 정성적 사례: (가) 대상 명칭이 제시되지 않은 경우, (나) 외형 특징으로만 식별 가능한 경우.

에서 47.40으로 0.33점 향상되었다. MC Accuracy와 LA Descriptive Avg는 각각 0.96%p와 1.49점 증가한 반면, SA Exact Match는 1.45%p 감소하였다. 따라서 데이터 증강으로 전체 성능은 소폭 향상되었지만 모든 문제 유형에서 일관된 개선이 나타나지는 않았다. 원본 데이터의 SA 문항이 숫자, 한자 등 폭넓은 정답 유형을 포함하는 것과 달리, 증강분은 좁은 범주에 편중되어 있어, 모델이 해당 패턴에 과적합되면서 SA 유형에 대한 일반화 성능이 저하되었다고 추측한다.

4.5 정성적 분석

Text Retrieval은 질문 또는 이미지에 대상을 특정할 수 있는 명칭이나 문자 정보가 있을 때 효과적이다. 그림 3(가)는 질문에 "암키와"와 "수키와"가 직접 제시되어 관련 문서를 검색한 사례이다. 검색 문서는 두 기와의 형태와 지붕에서의 역할에 관한 배경지식을 제공한다. 그림 3(나)는 이미지의 "서천군"을 질의어로 사용하여 관련 문서를 검색하고, 해당 지역이 충청남도에 속한다는 지식으로 상위 행정구역을 판단한 사례이다.

Image Retrieval은 질문이나 이미지의 문자 정보만으로 대상을 특정하기 어려울 때 유용하다. 그림 4(가)는 구체적 명칭이 없는 가구 이미지에서 시각적으로 유사한 장롱 문서를 검색한 사례이다. 그림 4(나)는 불단 뒤 그림의 명칭이 제시되지 않았지만 시각적으로 유사한 불교 회화 이미지를 검색하여 문화 대상 식별을 보조한 사례이다.

5. 결론

한국문화 멀티모달 VQA는 이미지 이해와 더불어 세부적인 문화 배경지식을 요구한다. 본 연구는 상대적으로 소형인 Kanana 3B를 기반으로 한국문화 외부 지식을 활용하는 Multimodal RAG 구조를 제안하였다. Text Retrieval은 질문, 선택지 및 이미지 내 문자 정보의 명시적 단서를 활용하고, Image Retrieval은 대상의 명칭이 드러나지 않는 경우에도 시각 특징으로 관련 지식을 검색한다. 두 경로를 결합한 Multimodal RAG는 종합 점수 47.07로 RAG를 적용하지 않은 Kanana보다 3.93점 높았고, EXAONE 33B의 46.99에 필적하는 성능을 보였다.

이 결과는 텍스트와 이미지 정보를 상호보완적으로 활용하는 한국문화 멀티모달 RAG의 가능성을 보여준다. 대규모 MLLM 내부에 방대한 도메인 지식을 모두 사전학습하는 대신, 소형 MLLM에 필요한 외부 지식을 동적으로 제공하는 방식이 한국문화 지식 기반 멀티모달 질의응답의 효과적인 대안이 될 수 있음을 확인하였다.

참고문헌

[1] E. Choi, K. Choi, S. Chun, S. Hong, J. Hwang *et al.*, "Exaone 4.5 technical report," *arXiv preprint arXiv:2604.08644*, 2026.

[2] Kakao Corp., "Kanana-1.5-V-3B-Instruct," Hugging Face Model Card, 2025. [Online]. Available: https://huggingface.co/kakaocorp/kanana-1.5-v-3b-instruct

[3] S. Bai, K. Chen, X. Liu, J. Wang, W. Ge *et al.*, "Qwen2.5-vl technical report," *arXiv preprint arXiv:2502.13923*, 2025.

[4] S. Bai, Y. Cai, R. Chen, K. Chen, X. Chen *et al.*, "Qwen3-vl technical report," *arXiv preprint arXiv:2511.21631*, 2025.

[5] Kanana LLM Team, Y. Bak, H. Lee, M. Ryu, J. Ham *et al.*, "Kanana: Compute-efficient bilingual language models," *arXiv preprint arXiv:2502.18934*, 2025.

[6] T. Mensink, J. Uijlings, L. Castrejon, A. Goel, F. Cadar, H. Zhou, F. Sha, A. Araujo, and V. Ferrari, "Encyclopedic vqa: Visual questions about detailed properties of fine-grained categories," *2023 IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 3090–3101, 2023.

[7] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin *et al.*, "Retrieval-augmented generation for knowledge-intensive nlp tasks," *Advances in Neural Information Processing Systems*, Vol. 33, 2020.

[8] V. Karpukhin, B. Oguz, S. Min, P. Lewis, L. Wu, S. Edunov, D. Chen, and W.-t. Yih, "Dense passage retrieval for open-domain question answering," *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, pp. 6769–6781, 2020.

[9] A. Asai, Z. Wu, Y. Wang, A. Sil, and H. Hajishirzi, "Self-rag: Learning to retrieve, generate, and critique through self-reflection," *International Conference on Learning Representations*, 2024.

[10] S.-Q. Yan, J.-C. Gu, Y. Zhu, and Z.-H. Ling, "Corrective retrieval augmented generation," *arXiv preprint arXiv:2401.15884*, 2024.

[11] W. Chen, H. Hu, X. Chen, P. Verga, and W. Cohen, "Murag: Multimodal retrieval-augmented generator for open question answering over images and text," *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pp. 5558–5570, 2022.

[12] D. Caffagni, F. Cocchi, N. Moratelli, S. Sarto, M. Cornia, L. Baraldi, and R. Cucchiara, "Wiki-llava: Hierarchical retrieval-augmented generation for multimodal llms," *2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, pp. 1818–1826, 2024.

[13] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "Lora: Low-rank adaptation of large language models," *arXiv preprint arXiv:2106.09685*, 2021.

[14] Y. Jang, J. Son, T. Lee, S. Hong, J. Park, and H. Lim, "Kure: Embedding model for korean-specific retrieval," *Annual Conference on Human and Language Technology*, pp. 129–134, 2025.

[15] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh *et al.*, "Learning transferable visual models from natural language supervision," *Proceedings of the 38th International Conference on Machine Learning*, 2021.

[16] 국립국어원, "[2026] 한국문화 멀티모달 질의응답," 2026.