한국문화 멀티모달 질의응답을 위한 멀티모달 검색 증강 생성

Multimodal Retrieval-Augmented Generation for Korean Culture Multimodal Question Answering

김준형† ⋆, 곽혜진†◦, 이신영†, 이정빈† | 홍익대학교 · 숙명여자대학교 · 고려대학교 · 성균관대학교
kimjunhyung0902@naver.com; hyejinkwak701@gmail.com; uriyoung11@korea.ac.kr; jeongbin511@gmail.com | † 공동 제1저자, ⋆ 교신저자, ◦ 발표자

HCLT 2026
2026년도 한글 및 한국어 정보처리 학술대회

Key Finding 한국문화 외부 지식을 텍스트와 이미지 두 경로로 검색하여 제공한 Kanana 3B + Multimodal RAG가 종합 점수 **47.07**를 달성하여, 한국문화를 사전학습한 33B EXAONE(**46.99**)를 상회했다.

01 INTRODUCTION

MLLM의 발전으로 이미지 기반 질의응답 성능이 향상되었지만, 한국문화 VQA는 이미지 이해뿐 아니라 문화재·유물·전통문화에 대한 배경지식을 요구한다. 대규모 MLLM은 이를 사전학습으로 습득할 수 있지만, 모델 규모와 학습 데이터에 크게 의존한다. 이에 본 연구는 소형 MLLM의 지식 한계를 외부 지식 검색으로 보완할 수 있는지 분석한다.

한국문화 지식을 강하게 사전학습한 EXAONE 4.5 33B와 경량 Kanana 1.5 V 3B를 비교하고, Kanana에 Text Retrieval과 Image Retrieval을 결합한 Multimodal RAG를 적용하여 대규모 모델과 경쟁 가능한 성능을 달성할 수 있는지 검증한다.

- EXAONE 33B와 Kanana 3B의 한국문화 VQA 성능을 비교한다.
- 텍스트·이미지 검색을 결합한 한국문화 Multimodal RAG를 제안한다.
- 3B MLLM + 외부 지식 검색이 33B MLLM과 경쟁 가능한 성능을 달성하는지 검증한다.

02 RELATED WORK

멀티모달 대규모 언어 모델. Qwen3-VL, Kanana 등 MLLM은 이미지·텍스트 이해 능력을 지속적으로 향상시켜 왔다. EXAONE 4.5는 한국문화 관련 멀티모달 데이터를 사전학습에 활용하였다. 하지만 Encyclopedic-VQA는 모델이 이미지를 이해하더라도 개체의 세부 지식 질문에는 취약함을 보여 외부 지식베이스 활용의 필요성을 시사한다.

검색 증강 생성. RAG는 검색된 외부 문서를 언어 모델에 제공하여 지식 한계를 보완한다. Self-RAG, Corrective RAG 등은 검색 품질과 생성 신뢰성을 개선했지만, 일반적인 Text RAG는 이미지의 시각 정보를 검색에 직접 활용하기 어렵다. 이를 보완하기 위해 MuRAG, Wiki-LLaVA 등 텍스트와 이미지를 함께 검색하는 Multimodal RAG가 연구되고 있다.

파라미터 효율적 미세조정. LoRA는 사전학습 가중치를 고정하고 저랭크 파라미터만 학습하여 효율적인 미세조정을 가능하게 한다. 본 연구는 Kanana의 attention projection layer에 LoRA를 적용하고, Shared Adapter에서 유형별 Adapter로 단계적으로 학습한다.

03 METHODS

전체 구조. 입력 이미지와 질문을 바탕으로 텍스트와 이미지 두 관점에서 관련 지식을 검색한다. Text Retrieval은 입력 이미지와 질문에서 얻은 언어적 단서를, Image Retrieval은 입력 이미지와 데이터베이스 이미지 사이의 시각적 유사도를 사용하며, 통합된 상위 문서의 설명을 RAG 참고정보로 구성하여 답변 생성 모델에 제공한다(Figure 1).

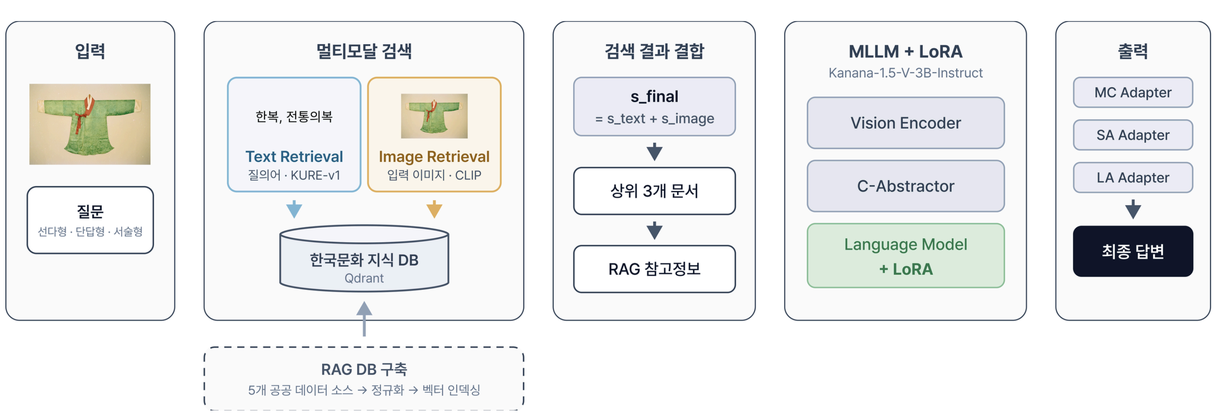


Figure 1. 제안하는 한국문화 멀티모달 RAG 프레임워크의 전체 구조

한국문화 지식 DB. 한국민족문화대백과사전, 한국민속대백과사전, 국립중앙박물관 e뮤지엄, 국가유산포털, 법제처의 5개 공공 데이터를 공통 스키마(doc_id, source, title, search_terms, description, image)로 정규화하였다. 각 문화 대상을 하나의 문서로 구성하고, 검색어에는 주요 명칭과 관련 표현을, 설명에는 Kanana에 제공할 외부 지식을 저장하였다. 정규화된 문서는 Qdrant 벡터 DB에 저장하고, 검색어는 한국어 임베딩 모델 KURE-v1, 이미지는 CLIP ViT-B/32로 벡터화하여 코사인 유사도로 검색한다.

Text 기반 지식 검색. Base Kanana가 이미지와 질문으로부터 명사구 중심 질의어를 최대 5개 생성한다. 질의어가 문서 제목과 정확히 일치하면 해당 문서를 직접 포함하고, 아니면 KURE-v1 임베딩과 문서 검색어 벡터의 코사인 유사도를 계산한다. m개의 질의어 집합 $Q = \{q_1, \ldots, q_m\}$에 대해 문서 점수를 식 (1)로 정의하고, $s_{\text{text}}(d_i) \geq 0.9$인 문서만 후보로 사용한다.

$$s_{\text{text}}(d_i) = \max_{q_j \in Q} s_{\text{text}}(d_i, q_j) \tag{1}$$

Image 기반 지식 검색. 입력 이미지를 검색 질의로 사용하여 텍스트 검색과 독립적으로 지식을 탐색한다. 입력 이미지 I와 문서 d_i의 n개 이미지 집합 $I_i = \{I_{i,1}, \ldots, I_{i,n}\}$ 중 가장 유사한 이미지의 CLIP 유사도를 점수로 하며(식 (2)), $s_{\text{image}}(d_i) \geq 0.9$인 문서만 후보로 사용한다.

$$s_{\text{image}}(d_i) = \max_{I_{i,j} \in I_i} \text{sim}\big(f_{\text{CLIP}}(I),\ f_{\text{CLIP}}(I_{i,j})\big) \tag{2}$$

검색 결과 결합. 두 경로의 후보를 doc_id로 통합하고, 같은 문서가 두 경로에서 모두 검색되면 두 점수를 함께 반영한다. 식 (3)으로 정렬해 최대 3개 문서의 설명을 참고정보로 제공한다. 후보가 없으면 제공하지 않으며, 검색 문서는 정답이 아닌 참고정보로 제공하고 무관한 정보는 무시하도록 프롬프트를 구성한다.

$$s_{\text{final}}(d_i) = s_{\text{text}}(d_i) + s_{\text{image}}(d_i) \tag{3}$$

단계적 Adapter 학습. MC·SA·LA 전체 train으로 Shared Adapter를 먼저 학습해 공통의 한국문화 지식 활용 능력을 익힌 뒤, 이를 동일한 초기값으로 MC·SA·LA 유형별 Adapter를 독립적으로 추가 학습한다. 이는 공통 능력을 공유하면서도 각 문제 유형에 특화된 응답 능력을 확보하기 위함이며, 추론 시 문항 유형에 맞는 Adapter로 최종 답변을 생성한다(Figure 2).

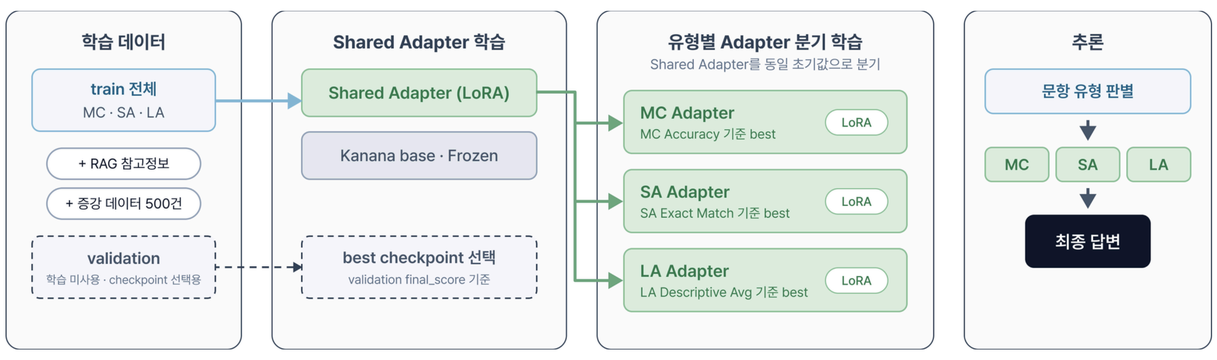


Figure 2. Shared Adapter 학습과 문항 유형별 Adapter 분기 학습

04 EXPERIMENTS

데이터셋 국립국어원 AI말평 한국문화 멀티모달 QA[16] - train 1,000 / validation 200 / test 800 (공식 평가 시스템으로 test 측정)

평가 지표 MC Accuracy, SA Exact Match, LA Descriptive Avg(ROUGE-1 F1·BLEU-1 평균), 종합 점수 = 세 지표의 산술평균

학습 설정 LM self-attention(q/k/v/o_proj)에 LoRA(r=16, α=32), Vision Encoder·Abstractor 고정. Shared: lr 2×10^{-5}, ≤5 epoch / 유형별: lr 1×10^{-5}, ≤10 epoch. Shared는 validation 종합 점수, 유형별은 MC Accuracy·SA Exact Match·LA Descriptive Avg 기준으로 최적 checkpoint를 선택하고, 2 epoch 연속 미향상 시 조기 종료

구분	모델	종합 점수	MC Acc	SA EM	LA Desc Avg
모델 비교	Kanana 3B	43.14	72.77	27.67	28.99
	EXAONE 33B	46.99	**75.90**	31.55	33.52
검색 방식	Kanana + Text RAG	45.11	72.29	28.64	34.39
	Kanana + Multimodal RAG	**47.07**	72.29	**32.52**	36.39
데이터 증강	+ Multimodal RAG + Data Aug	**47.40**	73.25	31.07	**37.88**

Table 1. 모델 및 검색 방식, 데이터 증강에 따른 한국문화 멀티모달 질의응답 성능 (test 800문항)

(가) 질문에 문화 대상의 명칭이 직접 제시된 경우



Q. 기와에는 암키와와 수키와가 있다.
사진을 보고 암키와와 수키와에 관해 올바르게 설명하고 있는 것을 모두 고르시오.

검색 질의어 생성 암키와 수키와 기와

'기와' 문서 검색 | 한국민족문화대백과사전

(나) 이미지 내 문자 정보가 검색 단서인 경우



Q. 해당 사업을 진행하는 군의 상위 지역을 4음절로 답하시오.

검색 질의어 생성 서천군

'서천군' 문서 검색 | 한국민족문화대백과사전

Figure 3. Text Retrieval 정성적 사례

(가) 질문에 대상의 명칭이 제시되지 않은 경우



Q. 다음 사진 속 가구의 주된 용도로 알맞은 것을 고르시오.

CLIP 이미지 임베딩 간 시각적 유사도 검색



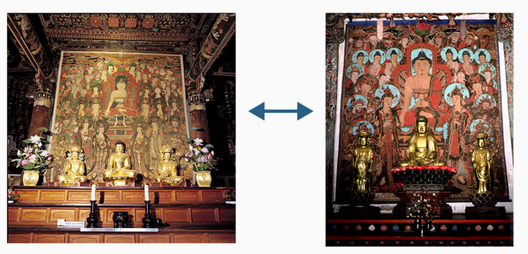
'장롱' 문서 검색 | 한국의식주생활사전

(나) 이미지의 외향적 특징으로만 식별 가능한 경우



Q. 불단 뒤에 걸린 커다란 불화를 무엇이라 부르는지 2음절로 답하시오.

CLIP 이미지 임베딩 간 시각적 유사도 검색



'탱화' 문서 검색 | 한국민족문화대백과사전

Figure 4. Image Retrieval 정성적 사례

정성적 분석. Text Retrieval은 질문이나 이미지에 대상을 특정할 명칭과 문자 정보가 있을 때 효과적이다. Figure 3의 (가)는 질문의 "암키와", "수키와"로 두 기와의 형태와 지붕에서의 역할에 관한 문서를, (나)는 이미지 속 "서천군"으로 문서를 검색해 충청남도라는 상위 행정구역을 판단한 사례이다. Image Retrieval은 문자 정보만으로 대상을 특정하기 어려울 때 유용하며, Figure 4의 (가)는 명칭 없는 가구 이미지에서 시각적으로 유사한 장롱 문서를, (나)는 불단 뒤 불화와 유사한 불교 회화 이미지를 통해 탱화 문서를 찾아 대상 식별을 보조한 사례이다.

05 CONCLUSIONS

- 소형 Kanana 3B에 한국문화 외부 지식을 결합하는 Multimodal RAG 구조를 제안하였다.
- Text Retrieval은 명시적 문자 단서를, Image Retrieval은 명칭이 없는 대상의 시각 특징을 활용한다.
- Multimodal RAG는 종합 47.07로 RAG 미적용 대비 +3.93, EXAONE 33B(46.99)에 필적하였다.
- 텍스트와 이미지 정보를 상호보완적으로 활용하는 한국문화 멀티모달 RAG의 가능성을 확인하였다.
- 대규모 MLLM에 모든 도메인 지식을 사전학습하는 대신, 소형 MLLM에 외부 지식을 동적으로 제공하는 방식이 한국문화 KB-VQA의 효과적 대안이 될 수 있다.